Propuesta de Proyecto: Reasoning RecSys — VLM LatentR3

IIC3633 Sistemas Recomendadores — 2026-2

Grupo 2: Cristian Troncoso, Mauricio Annicchiarico, Tomás Salinas

1. Descripción del Problema y Justificación.

1.1. Contexto y Limitaciones del Razonamiento Explícito

Los sistemas de recomendación han transitado del filtrado colaborativo estático hacia la recomendación secuencial basada en retroalimentación implícita, destacando modelos recurrentes (GRU4Rec) y de autoatención (SASRec). Aunque capturan dependencias temporales, su dependencia exclusiva de identificadores discretos (Item-IDs) limita su comprensión semántica y agrava la dispersión de datos (sparsity). La adopción de Grandes Modelos de Lenguaje (LLMs) ha permitido incorporar contenido semántico; no obstante, aplicar razonamiento en cadena de pensamiento explícita (Chain-of-Thought, CoT) presenta dos barreras críticas: escasez de trazas de razonamiento supervisadas en registros de compra y latencia computacional inadmisible al decodificar explicaciones paso a paso en tiempo real.

1.2. Razonamiento Latente Reforzado

Para superar esta limitación, Zhang et al. (2026) proponen LatentR3, que traslada el razonamiento al espacio de representaciones continuas del LLM. Para ello agregan una capa de atención (LatentRATT) que genera tokens de razonamiento latente antes de la predicción del siguiente ítem. El entrenamiento tiene dos etapas: un ajuste supervisado (SFT) que inicializa el módulo de razonamiento, seguido de aprendizaje por refuerzo con una versión modificada de GRPO. En esta versión, las trayectorias latentes se muestrean agregando ruido gaussiano al token de razonamiento. La recompensa es continua el negativo de la perplejidad del ítem objetivo, lo que evita generar la respuesta completa para cada muestra. Además, la ventaja se calcula respecto del promedio del batch y no del grupo. Así, el modelo aprende a razonar sin trazas de razonamiento supervisadas, con un costo de inferencia equivalente a generar un token adicional.

1.3. Justificación

Pese a su eficacia, LatentR3 es estrictamente unimodal (textual). En catálogos de comercio electrónico de Amazon (Toys and Games, Video Games, CDs and Vinyl, Musical Instruments), la modalidad visual es crítica en la decisión de compra: el diseño, color, empaque y estética comunican factores que el texto rara vez explicita. Los métodos multimodales previos (e.g., VBPR) solo concatenan embeddings estáticos, mientras que emplear Modelos de Visión y Lenguaje (VLMs) con CoT explícito multiplicaría la latencia. Por ello, proponemos VLM

LatentR3: extender el razonamiento latente reforzado a un backbone VLM, permitiendo razonar conjuntamente sobre imágenes y texto en el espacio continuo con GRPO, enriqueciendo la recomendación secuencial sin penalizar la latencia.

2. Objetivos del Proyecto

2.1. Objetivo General

Diseñar, implementar y evaluar VLM LatentR3, una extensión multimodal de razonamiento latente para recomendación secuencial que combine representaciones visuales y textuales mediante un backbone VLM optimizado con Group Relative Policy Optimization (GRPO), evaluando su efectividad y eficiencia inferencial frente a baselines clásicos y secuenciales en datasets de Amazon 2018.

2.2. Objetivos Específicos

1. **Datos y Baselines de Referencia:** Preprocesar los catálogos de Amazon (filtrado 5-core e indexación multimodal) e implementar baselines de referencia, simples (Random, Most Popular y Last-Item) y secuenciales (SASRec/GRU4Rec), y generativos (BIGRec) evaluados con Hit Ratio@K y NDCG@K (K = 5, 10).
2. **Replicación Unimodal de LatentR3:** Reproducir el pipeline original de LatentR3 (LLM textual con tokens latentes y GRPO) para fijar el límite de referencia unimodal.
3. **Diseño e Implementación de VLM LatentR3:** Formular la arquitectura multimodal integrando imágenes mediante un encoder visual/VLM backbone (e.g., SigLIP o Qwen2-VL) y adaptar las etapas de SFT y refuerzo (GRPO) sobre el espacio latente.
4. **Evaluación Comparativa y Ablación:** Medir la calidad predictiva (Hit@K, NDCG@K) y la latencia inferencial frente a los baselines, cuantificando el impacto real de incorporar la modalidad visual frente a variantes puramente textuales.

3. Análisis descriptivo de los datos

Utilizamos cuatro categorías de Amazon Review Data 2018 (Ni et al., 2019): Toys, CDs y Games, como en el paper original, más Instruments. Las preprocesamos con la función del repositorio de LatentR3. Esta descarta los ítems sin título válido, aplica un filtro 5-core en una ventana temporal que termina en octubre de 2018 y que se extiende hasta superar los 5.000 ítems, usa historiales de hasta 10 ítems y divide los datos temporalmente en 80/10/10.

3.1. Sparsity y tamaño

Entrenamiento						
Dataset	**Usuarios**	**Secuencias (con cada paso)**	**Ítems**	**Interacciones user-item**	**Largo Prom. Historial**	**Sparsity**
games_data	12,119	75,175	5,251	85,036	7.02	99.8664%

cd_data	6,865	49,251	5,837	54,777	7.98	99.8633%
toys_data	10,167	53,898	6,269	61,326	6.03	99.9038%
music_data	10,899	66,500	5,010	73,302	6.73	99.8658%

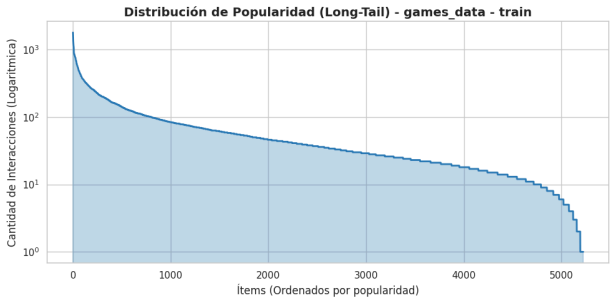
Tabla 1. Estadísticas de los datasets de Entrenamiento

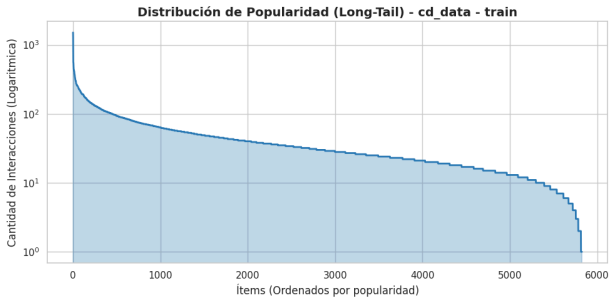
Validación						
Dataset	**Usuarios**	**Secuencias (con cada paso)**	**Ítems**	**Interacciones**	**Largo Prom. Secuencia**	**Sparsity**
games_data	1,907	9,397	4,987	15,222	7.98	99.8399%
cd_data	3,255	6,156	4,574	23,469	7.21	99.8424%
toys_data	3,082	6,737	4,520	22,000	7.14	99.8421%
music_data	2,455	8,312	5,136	15,586	6.35	99.8764%

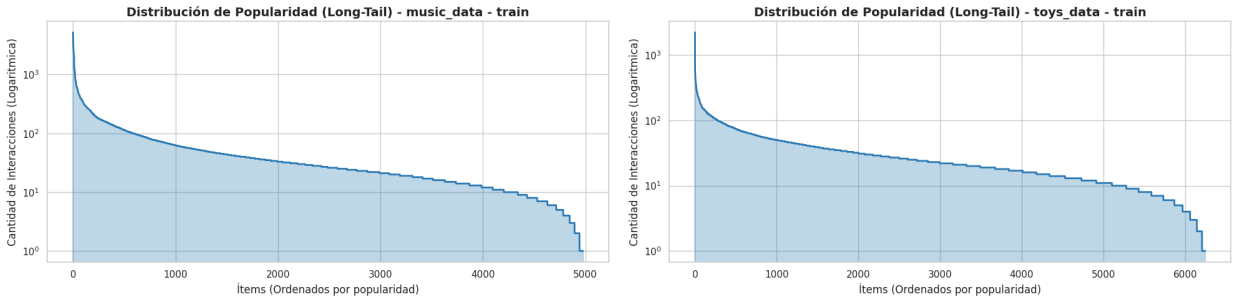
Tabla 2. Estadísticas de los datasets de Validación

Los datos de las tablas muestran características relevantes sobre el comportamiento de los usuarios en los respectivos catálogos. En primer lugar se tiene un volumen de interacciones en el conjunto de entrenamiento con un tamaño suficiente para el entrenamiento de modelos basados en deep learning, para el algoritmo GRPO esto provee un volumen suficiente de datos para tener un espacio de exploración respecto al aprendizaje por refuerzo. En segundo lugar se observa Sparsity o dispersión alta en todos los dominios, lo que implica para modelos basados en señales colaborativas se tiene una matriz de interacción casi vacía, por lo que incluir conocimiento externo como las imágenes que se ve aprovechado en gran medida por los VLMs resalta la relevancia del proyecto.

3.2. Gráficos de Popularidad



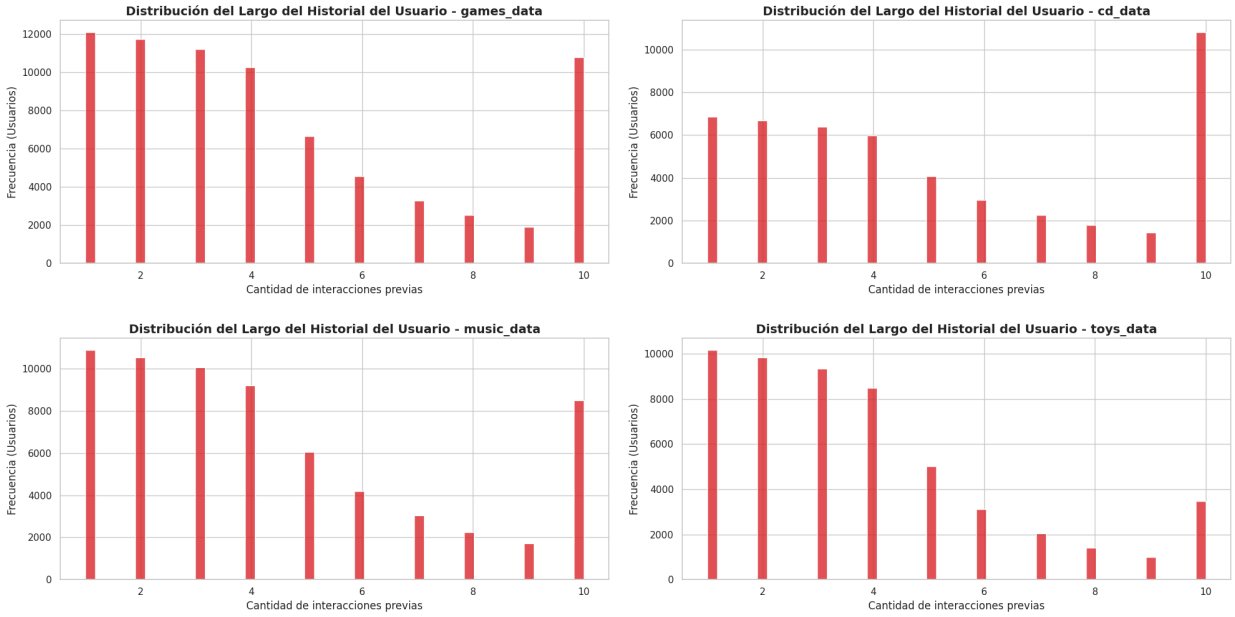




Gráficos 1-4. Distribuciones de popularidad por dataset en entrenamiento (escala logarítmica)

Los gráficos de popularidad confirman la acumulación de una gran parte de las interacciones en un pequeño grupo de ítems, observable de la caída vertical al inicio de cada gráfico. A medida que se avanza por el eje x se ve que una gran cantidad de ítems se encuentran entre las 100 a 10 interacciones, y en algunos datasets con una cantidad considerable de ítems entre 10 a 1 interacciones. Lo anterior produce un impacto en los Baselines como GRU4Rec/SASRec, resultando en un sobreajuste a los ítems más populares. Para el modelo propuesto VLM LatentR3 se espera que reduzca notablemente este sesgo de popularidad, dado que utiliza datos como la imagen y título para inferir la categoría o estética de un ítem para ver si encaja con el historial del usuario, tendrá una dependencia reducida en las compras o popularidad del ítem para la recomendación.

3.3. Distribución del Largo de Historiales



Gráficos 5-8. Distribuciones del largo de Historial por dataset en entrenamiento

Se puede observar que en 3 de los datasets se tienen historiales de 10 interacciones con gran frecuencia lo que beneficia a modelos como SASRec y GRU4Rec para extraer patrones de comportamiento a lo largo del tiempo, pero también se observan una gran cantidad de historiales de largo 1 a 4, en los cuales estos modelos tienen pocos pasos previos para aprender, por lo que en esos casos les falta contexto suficiente para inferir el próximo ítem. Para el modelo propuesto lo anterior no es un impedimento, dado que a través de las imágenes y texto de un historial corto puede extraer un perfil latente del historial con una mayor cantidad de contexto.

3.4. Distribución de Ratings Porcentual

Dataset	1 Estrellas (%)	2 Estrellas (%)	3 Estrellas (%)	4 Estrellas (%)	5 Estrellas (%)
games_data	4.87%	3.07%	7.20%	14.47%	70.38%
cd_data	0.94%	1.30%	4.37%	13.28%	80.10%
toys_data	1.74%	2.09%	5.76%	14.14%	76.27%
music_data	2.43%	2.73%	6.32%	15.75%	72.77%

Tabla 3. Distribución de ratings por dataset en entrenamiento

En la tabla de ratings se puede observar que existe un fuerte sesgo a las valoraciones positivas, el motivo principal de esto se debe a que los usuarios suelen calificar principalmente los productos que les gustaron mucho, por lo que la predicción de rating pierde valor y se explica la preferencia en métricas de ranking.

3.5. Cold Start y Dinamica Temporal

Dataset	Ítems Cold-Start (<=5)	% Cold-Start
games_data	203	3.82%
cd_data	154	2.64%
toys_data	378	6.00%
music_data	264	5.25%

Tabla 4. Porcentaje de ítems en cold start por dataset

Dataset	Brecha Mediana (Días)	Brecha Promedio (Días)
games_data	0.0	23.8
cd_data	0.0	19.5
toys_data	0.0	15.0
music_data	0.0	33.1

Tabla 5. Tiempo entre compras en historiales

El filtro 5-core garantiza que cada usuario e ítem tenga al menos 5 interacciones dentro de la ventana temporal. Sin embargo, tras la división temporal, un ítem puede quedar con menos de 5 apariciones en el conjunto de entrenamiento, que es lo que mide la Tabla 4.

Estas tablas muestran dos situaciones relevantes para evaluar nuestra propuesta. Primero, entre un 2,6% y un 6,0% de los ítems tiene muy pocas interacciones en entrenamiento, por lo que los modelos basados solo en identificadores cuentan con poca señal para recomendarlos. Nuestra hipótesis es que VLM LatentR3, al usar las imágenes y los títulos, podrá recomendar mejor estos ítems, y lo evaluaremos comparando el desempeño por nivel de popularidad. Segundo, las brechas entre compras son muy variables. La mediana de 0 días indica que muchas reseñas se publican el mismo día (las fechas tienen resolución diaria y corresponden a la publicación de la reseña), mientras que el promedio, de 15 a 33 días, refleja historiales con compras muy espaciadas.

4. Implementación de modelos de referencia

Para esta entrega inicial se implementaron los baselines estándar de referencia: Random, MostPop y Last-Item (heurística secuencial basada en los ítems más recientes del usuario). Para la etapa del Midterm, él marco experimental incorporará los modelos neuronales especificados en la propuesta (*GRU4Rec, SASRec, Caser).*

Los resultados muestran patrones divergentes según la naturaleza de cada catálogo. En CDs and Vinyl e Instruments, MostPop supera consistentemente a Historial Reciente (alcanzando HR@10 de 0.0192 y 0.0659, respectivamente), lo que refleja que en estos dominios las preferencias están fuertemente concentradas en un subconjunto reducido de ítems populares y la tasa de recompra es menor.

Por el contrario, en Toys and Games (HR@10 de 0.0197 vs. 0.0137) y Video Games (HR@10 de 0.0327 vs. 0.0204), Historial Reciente + MostPop supera ampliamente a MostPop (un aumento de +43% y +60% en HR@10, respectivamente). Esto evidencia una fuerte inercia de re-consumo e interacción sobre ítems ya conocidos en estos dominios.

Estos hallazgos demuestran que las heurísticas simples solo capturan facetas aisladas (popularidad global o re-consumo directo). Para la etapa de Midterm (H2), el marco experimental incorporará los modelos secuenciales y neuronales del estado del arte especificados en la propuesta (Caser, GRU4Rec, SASRec), con el fin de evaluar transiciones

de compra genuinas hacia ítems nuevos, sirviendo de base para contrastar nuestra propuesta VLM LatentR3.

#	dataset	modelo	HR@5	NDCG@5	HR@10	NDCG@10
0	cd_data	Random	0.0008	0.0004	0.0018	0.0007
1	cd_data	MostPop	**0.0130**	0.0081	**0.0192**	0.0101
2	cd_data	Last-tem (Secuencial)	0.0119	**0.0110**	0.0151	**0.0120**
3	music_data	Random	0.0017	0.0009	0.0026	0.0012
4	music_data	MostPop	**0.0410**	**0.0268**	**0.0659**	**0.0348**
5	music_data	Last-Item (Secuencial)	0.0250	0.0131	0.0541	0.0225
6	toys_data	Random	0.0012	0.0006	0.0021	0.0008
7	toys_data	MostPop	0.0098	0.0071	0.0137	0.0083
8	toys_data	Last-Item (Secuencial)	**0.0150**	**0.0135**	**0.0197**	**0.0150**
9	games_data	Random	0.0009	0.0006	0.0021	0.0011
10	games_data	MostPop	0.0131	0.0086	0.0204	0.0110
11	games_data	Last-Item (Secuencial)	**0.0246**	**0.0221**	**0.0327**	**0.0246**

Tabla 6. Resultados de HR@5-10 y NDCG@5-10 para los modelos de referencia básicos sobre los datasets de amazon. Los resultados más altos están en negrita.

5. Planificación para la etapa Midterm

Semana	Foco	Tareas Clave	Criterio de Éxito
S1 (12-18 Oct)	**Datos Multimodales**	Extracción de embeddings visuales (SigLIP/CLIP) e indexación pareada texto-imagen.	Catálogo 100% indexado con texto e imágenes.
S2 (19-25 Oct)	**Baselines Secuenciales y Generativos**	Ajuste y evaluación formal de baselines clásicos (GRU4Rec, SASRec, BIGRec).	Tabla comparativa de baselines (Hit@10, NDCG@10).
S3 (26 Oct - 1 Nov)	**Replicación & Setup VLM**	Replicación de LatentR3 unimodal y	Convergencia de pérdida en SFT

		pruebas iniciales de SFT multimodal con VLM.	multimodal.
S4 (2-6 Nov)	**RL & Entrega Midterm**	Fase de refuerzo con GRPO multimodal y redacción de resultados preliminares.	Informe Midterm H2 entregado (06 de Noviembre).

6. Bibliografía

1. Zhang, Y., et al. (2026). Reinforced Latent Reasoning for LLM-based Recommendation. ICLR 2026.
2. Kang, W. C., & McAuley, J. (2018). *Self-Attentive Sequential Recommendation*. In *Proc. of IEEE ICDM*, pp. 197–206.
3. Hidasi, B., et al. (2015). *Session-based recommendations with recurrent neural networks*. In *ICLR 2016*.
4. He, R., & McAuley, J. (2016). *VBPR: Visual Bayesian Personalized Ranking from Implicit Feedback*. In *Proc. of AAAI*, 30(1).
5. Shao, Z., et al. (2024). *DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models (GRPO)*. arXiv:2402.03300.